

```
[5]
           1 import re
            3 # '한글'을 제외한 다른 문자 모두 제거
{x}
            4 remove_except_ko = re.compile(r"[^가-힣¬-ㅎト-|\\s]")
            5 def preprocess_remove(text):
                  text = re.sub(remove_except_ko,' ',text).strip()
return text
            8
            9 df['document'] = df['document'].map(lambda x : preprocess remove(x))
           1 from konlpy.tag import Okt
            3 # 토큰화 / 불용어처리
            4 stop_pos = ['Josa', 'Eomi', 'Punctuation', 'Foreign', 'Number', 'Unknown', 'KoreanParticle']
            5 stop_word = ['영화']
            6
            7 tokenizer= 0kt()
            8 df['morphs'] = None
            9 for i,row in df.iterrows():
           10 tokens = tokenizer.pos(row['document'])
           11 token_ls = []
           12 for token in tokens:
                 if len(token[0]) > 1:
           13
           14
                   if token[0] not in stop_word:
                      if token[1] not in stop_pos:
           15
           16
                        token_ls.append(token[0])
           17 # print(token_ls)
           18 df['morphs'][i] = ' '.join(token_ls)
            1 from sklearn.model_selection import train_test_split
            2 from tensorflow.keras.preprocessing.text import Tokenizer
            4 X_train, X_test, y_train, y_test = train_test_split(df['morphs'], df['label'], random_state = 0)
            6 tokenizer = Tokenizer() # 선언
            7 # make train word set
            8 tokenizer.fit_on_texts(X_train)
      [9]
            1 print(len(tokenizer.word_index))
            2 tokenizer.word_index
          16111
           {'정말': 1,
            '너무': 2,
            '진짜': 3,
            '연기': 4,
            '평점': 5,
            '최고': 6,
<>
            '스토리': 7,
            '사람': 8,
\equiv
            '보고': 9,
```

```
[9]
           '이런': 10,
Q
           '드라마': 11,
           '하는': 12,
           '생각': 13,
{x}
           '감동': 14,
           '시간': 15,
           '그냥': 16,
'감독': 17,
           '배우': 18,
           '내용': 19,
           '재미': 20,
           '쓰레기': 21,
           '없는': 22,
           '작품': 23,
           '사랑': 24,
           '하나': 25,
           '주인공': 26,
           '없다': 27,
           '이건': 28,
           '있는': 29,
           '같은': 30,
           '정도': 31,
           '다시': 32,
           '마지막': 33,
           '이렇게': 34,
           '봤는데': 35,
           '액션': 36,
           '완전': 37,
           '처음': 38,
           '연출': 39,
           '입니다': 40,
           '장면': 41,
           '최악': 42,
           '지금': 43,
           '느낌': 44,
           '역시': 45,
           '명작': 46,
           '없고': 47,
           '보는': 48,
           '이야기': 49,
           '봐도': 50,
           '그리고': 51,
           '별로': 52,
           '좋은': 53,
           '많이': 54,
           '보면': 55,
           '같다': 56,
           '이해': 57,
           1 X_train[:2]
                                                  존경 하시는
      \supseteq
          2967
          700
                  음악 취향 저격 비긴 어게인 대중 흥행 하긴 힘들 하지만 여주 너무 매력
          Name: morphs, dtype: object
```

포프 . 9,

<>

```
✓ [11] 1 #단어를 숫자배열로 변환
            2 X_train_arrary_list = tokenizer.texts_to_sequences(X_train)
            3 X_test_arrary_list = tokenizer.texts_to_sequences(X_test)
{x}
            5 # 레이블링 데이터 행렬변환
            6 Y_train = np.array(y_train) # 형 변환 : x 와 타입을 동일하게 맞춰주기 위해서 진행
7 Y_test = np.array(y_test)
            8 print('훈련데이터 X: ',len(X_train_arrary_list))
            9 print('훈련데이터 Y: ',len(Y_train))
          훈련데이터 X: 7500
          훈련데이터 Y: 7500
   √
0초 [12] 1 # 확인
            2 print(X_train[:2])
            3 print(X_train_arrary_list[:2])
          2967
                                                   존경 하시는
          700
                  음악 취향 저격 비긴 어게인 대중 흥행 하긴 힘들 하지만 여주 너무 매력
          Name: morphs, dtype: object
          [[616, 1616], [118, 464, 5826, 3548, 3549, 1985, 295, 1986, 1987, 77, 351, 2, 74]]
           1 print('리뷰의 최대 길이 :', max(len(l) for l in X_train))
            2 print('리뷰의 평균 길이 :',sum(map(len, X_train))/len(X_train))
            3 plt.hist([len(s) for s in X_train], bins=30)
            4 plt.xlabel('length of samples')
            5 plt.ylabel('number of samples')
            6 plt.show()
      → 리뷰의 최대 길이 : 149
          리뷰의 평균 길이 : 26.0936
              1200
              1000
           number of samples
               800
               600
               400
               200 -
<>
\equiv
                     0
                            20
                                   40
                                          60
                                                 80
                                                       100
                                                              120
                                                                     140
```

```
Q < [14] 1 # 편하게 사용하기 위해서 재 할당
           2 X_train = X_train_arrary_list
            3 X_test = X_test_arrary_list
{x}
[15] 1 from tensorflow.keras.preprocessing.sequence import pad_sequences
            3 # 데이터 길이 35로 패딩
            4 \max_{len} = 35
            5 X_train = pad_sequences(X_train, maxlen = max_len)
            6 X_test = pad_sequences(X_test, maxlen = max_len)
   // [16] 1 X_train[0]
          array([ 0,
                                                                               0,
                    0,
                                                                               0,
                                                                               0,
                  616, 1616], dtype=int32)
    ▼ part2. 모델링
   ✓ [17] 1 # 구글 드라이브 경로 설정
            2 path = '/content/'
   [18] 1 from tensorflow.keras.layers import Embedding, Dense, LSTM
            2 from tensorflow.keras.models import Sequential
            3 from tensorflow.keras.models import load_model
            4 from tensorflow.keras.callbacks import EarlyStopping, ModelCheckpoint
            6 vocab_size = len(X_train) # 학습데이터 길이 = vocab size
            7 embedding_dim = 100
            9 model = Sequential() # 모델 선언
           10 model.add(Embedding(vocab_size, embedding_dim))
           11 model.add(LSTM(128))
           12 model.add(Dense(128, activation='relu'))
           13 model.add(Dense(64, activation='relu'))
           14 model.add(Dense(8, activation='relu'))
           15 model.add(Dense(1, activation='sigmoid'))
```

```
참고
     • monitor : 학습 조기종료를 위해 관찰하는 항목 (default : val_loss)
{x}
     • patience: 개선이 안된다고 바로 종료시키지 않고, 개선을 위해 몇번의 에포크를 기다릴지 설정 (default = 0)
• verbose : 언제 traing을 멈추었는지에 대한것을 화면에 출력할지 여부(1 = 출력)
     • mode : 관찰항목에 대해 개선이 없다고 판단하기 위한 기준을 설정. monitor에서 설정한 항목이 val loss 이면 값이 감소되지 않을 때 종료하여야 하므로
      min 을 설정하고, val_accuracy 의 경우에는 max를 설정해야함. (default = auto)
        ○ auto: monitor에 설정된 이름에 따라 자동으로 지정
        o min: 관찰값이 감소하는 것을 멈출 때, 학습을 종료
        o max: 관찰값이 증가하는 것을 멈출 때, 학습을 종료
  \frac{\checkmark}{0.5} [19] 1 # 검증 데이터 손실(val_loss)이 증가하면, 과적합이 될수 있기 때문에 검증 데이터 손실이 4회 증가하면 학습을 조기 종료(Early Stopping).
       2 # ModelCheckpoint를 사용하여 검증 데이터의 정확도(val_acc)가 이전보다 좋아질 경우에만 모델을 저장
       3 es = EarlyStopping(monitor='val loss', mode='min', verbose=1, patience=4)
       4 mc = ModelCheckpoint('./data/naver_movie_model_lstm', monitor='val_acc', mode='max', verbose=1, save_best_only=True)
                                                                                      个 ↓ ⑤ 目 ♬ ♬ 盲
       1 # generate model
       2 # loss = 'sparse_categorical_crossentropy' # 분류모델사용
       3 model.compile(optimizer='rmsprop', loss='binary crossentropy', metrics=['acc'])
       4 history = model.fit(X train, Y train, epochs=15, callbacks=[es, mc], batch size=16, validation split=0.2)
    → Epoch 1/15
      Epoch 1: val_acc improved from -inf to 0.61867, saving model to ./data/naver_movie_model_lstm
      Epoch 2/15
      Epoch 2: val_acc improved from 0.61867 to 0.74733, saving model to ./data/naver_movie_model_lstm
      Epoch 3/15
      Epoch 3: val_acc improved from 0.74733 to 0.76733, saving model to ./data/naver_movie_model_lstm
      Epoch 4/15
      Epoch 4: val acc improved from 0.76733 to 0.77667, saving model to ./data/naver movie model lstm
      Epoch 5/15
      Epoch 5: val_acc improved from 0.77667 to 0.77733, saving model to ./data/naver_movie_model_lstm
```

```
Epoch 6/15
                                                                                            ↑ ↓ © 目 ‡ 1 1 :
       Q
       Epoch 6: val_acc did not improve from 0.77733
       Epoch 7/15
{x}
       Epoch 7: val_acc did not improve from 0.77733
Epoch 7: early stopping
  79/79 [============== ] - 0s 4ms/step - loss: 0.6052 - acc: 0.7736
       테스트 정확도: 0.7736

y_ [22] 1 y_predict = model.predict(X_test)

        2 y_predict
       79/79 [======== ] - 1s 3ms/step
       array([[0.86680305],
           [0.9985902],
           [0.9991875],
           [0.35415748],
           [0.00227166],
           [0.98270744]], dtype=float32)
  \sum_{n=1}^{\infty} [23] 1 y_predict2 = []
        2 for x in y_predict:
        3 if x \ge 0.5:
           y_predict2.append(1)
        5 else:
           y_predict2.append(0)
    0
       1 from sklearn.metrics import classification_report
       2 print(classification_report(y_test,y_predict2, target_names=['부정( 0 )', '긍정( 1 )']))
    \Box
                        recall f1-score support
                precision
          부정(0)
                   0.74
                          0.85
                                0.79
                                      1248
          긍정(1)
                   0.83
                          0.69
                                0.75
                                      1252
                                0.77
                                      2500
         accuracy
                   0.78
                         0.77
                                0.77
                                      2500
         macro avg
       weighted avg
                   0.78
                         0.77
                                0.77
                                      2500
    [] 1
<>
    [] 1
```